SIMULACIÓN Y MODELOS PARA EL ANÁLISIS DE DATOS ACTUARIALES Y FINANCIEROS

Departamento de Economía y Dirección de Empresas.

Máster en Ciencias Actuariales y Financieras.

Profesor: **David Atance del Olmo**

david.atance@uah.es

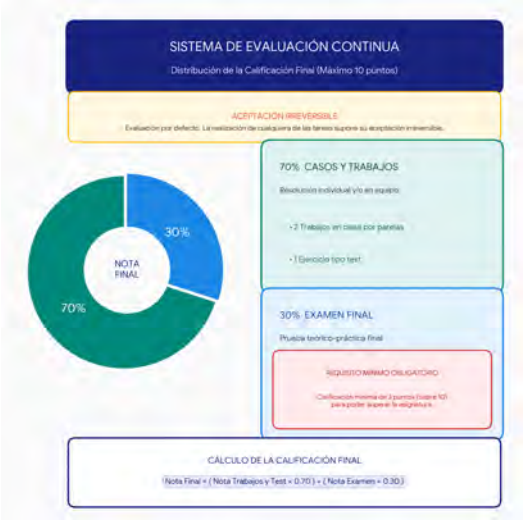


Departamento Economía
y Dirección de Empresas
UAH

Conceptos a tratar en la asignatura

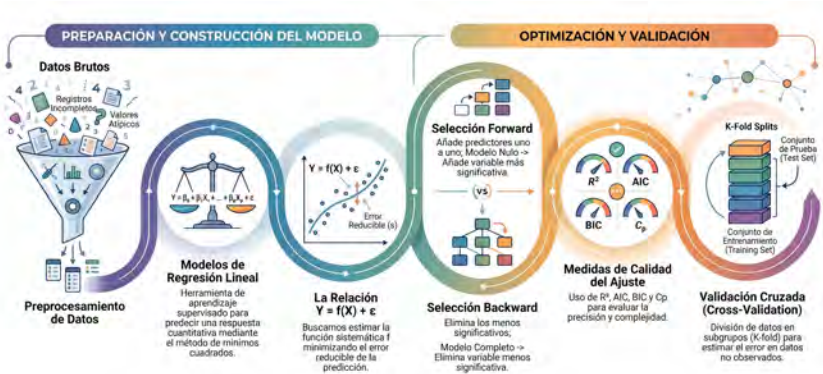


Conceptos a tratar en la asignatura



Tema 2:
Modelos de regresión lineal.

Índice


PREPARACIÓN Y CONSTRUCCIÓN DEL MODELO
OPTIMIZACIÓN Y VALIDACIÓN
Datos Brutos
Registros Incompletos
Valores Atípicos
Preprocesamiento de Datos
Modelos de Regresión Lineal
Herramienta de aprendizaje supervisado para predecir una respuesta cuantitativa mediante el método de mínimos cuadrados.
Y = f(X) + ε
Error Reducible (ε)
La Relación Y = f(X) + ε
Buscamos estimar la función sistemática f minimizando el error reducible de la predicción.
Selección Forward
Añade predictores uno a uno; Modelo Nulo -> Añade variable más significativa.
vs
Selección Backward
Elimina los menos significativos;
Modelo Completo -> Elimina variable menos significativa.
R²
AIC
BIC
Cp
Medidas de Calidad del Ajuste
Uso de R², AIC, BIC y Cp para evaluar la precisión y complejidad.
K-Fold Splits
Conjunto de Prueba (Test Set)
Conjunto de Entrenamiento (Training Set)
Validación Cruzada (Cross-Validation)
División de datos en subgrupos (K-fold) para estimar el error en datos no observados.

Índice

- 2.1. Preprocesamiento de los datos.
- 2.2. Modelos de Regresión Lineal.
- 2.3. Medidas de validación de modelos.
- 2.4. Proceso de decisión Forward and Backward stepwise.
- 2.5. Cross-Validation.

2.1. Preprocesamiento de los datos.

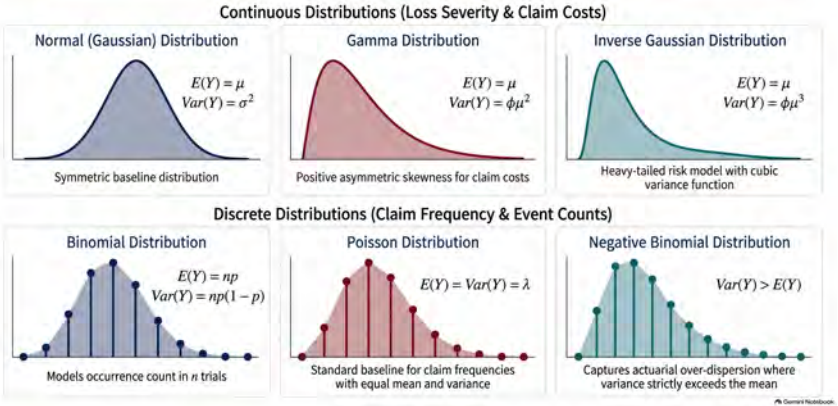
Desarrollo de cualquier proceso de un científico de datos:



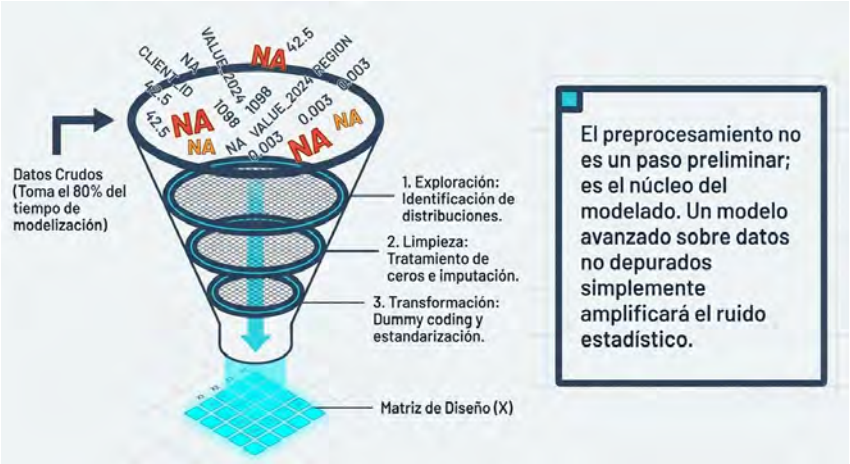
2.1. Preprocesamiento de los datos.

- 2.1.1. Etapas clave.
- 2.1.2. Deficiencias comunes en los datos.
- 2.1.3. ¿Qué hacer con los datos ausentes?.
- 2.1.4. Transformación variables categóricas.
- 2.1.5. Transformación variables continúas.

2.1.1. Etapas clave.



2.1.1. Etapas clave.



2.1.1. Etapas clave.

El ciclo iterativo de un científico de datos consta de tres pasos clave:

1. Establecer expectativas o hipótesis iniciales.
2. Recopilar información (datos) y compararla con las expectativas planteadas, y si los datos no coinciden con dichas expectativas,
3. Evaluar las expectativas o los datos, de modo que exista coherencia entre los datos observados y las expectativas formuladas



2.1.1. Etapas clave.



2.1.1. Etapas clave.

Definición Marco ISO/IEC 25012 → LEGISLACIÓN.

Definición: proceso riguroso de diagnóstico para validar que los conjuntos de datos cumplan con las dimensiones de **completitud, consistencia, exactitud y validez** antes de la fase de modelado.

Se busca identificar los problemas que pueden presentar los datos, ya que introducen sesgo o degradan el poder predictivo de los algoritmos.

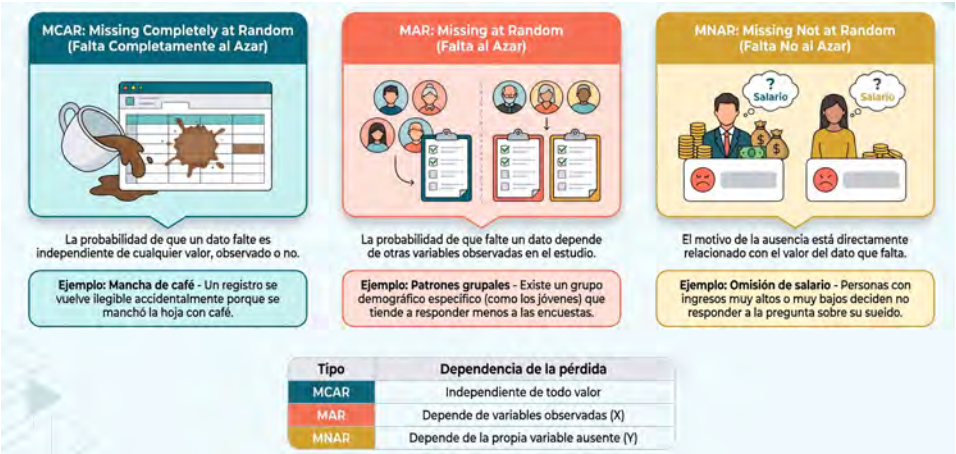
El objetivo final de auditar la calidad del dato antes de alimentar los modelos de Machine Learning se resume en: "***Garbage In, Garbage Out***"

2.1. Preprocesamiento de los datos.

- 2.1.1. Etapas clave.
- 2.1.2. Deficiencias comunes en los datos.
- 2.1.3. ¿Qué hacer con los datos ausentes?.
- 2.1.4. Transformación variables categóricas.
- 2.1.5. Transformación variables continúas.

2.1.2. Deficiencias comunes en los datos

.



2.1.2. Deficiencias comunes en los datos

.

Valores atípicos y datos anómalos (Outliers): Observaciones alejadas de la distribución normal o estructura poblacional. Ejemplo: movimientos entre $3,000$-$50,000$ euros y aparece un movimiento de $100,000,000$ euros.

Distancia de Mahalanobis o Detección Multivariante con Correlación (Mahalanobis, 1936). Mide la distancia de un punto a un centroide multivariante teniendo en cuenta la covarianza y correlación entre variables. A diferencia de la distancia euclídea, detecta puntos que rompen la relación normal entre dos o más variables. Ejemplo: En un análisis de riesgo crediticio donde se evalúan los ingresos anuales y el límite de la tarjeta concedido. Por ejemplo:

- Si alguien gana 150,000 euros/año, se le concede un límite de 15,000.
- Si alguien gana 15,000 euros/año, se le concede un límite de 1,500.
- Un cliente solicita 15,000 euros de límite teniendo unos ingresos de apenas 10,000 euros. La distancia de Mahalanobis detectará este punto como una anomalía clara porque se sale del eje de correlación habitual entre ingresos y crédito concedido.

2.1.2. Deficiencias comunes en los datos

.

Los datos no informativos (Uninformative Data) aquellos atributos o variables que no aportan valor predictivo ni capacidad de discriminación a un modelo, introduciendo coste computacional innecesario y riesgo de sobreajuste (overfitting). Encontramos dos tipos fundamentales:

- Varianza Nula o Casi Nula (Zero Variance) (Kuhn and Johnson, 2013). Ocurre cuando el valor de una columna es prácticamente constante para casi todas las observaciones de la muestra. $\text{Var}(X) = 0$, todos registros mismo valor $\rightarrow$ la variable no aporta nada.
- Varianza Casi Nula (Near-Zero Variance - NZV). Una variable tiene varianza casi nula cuando toma un único valor en la inmensa mayoría de las observaciones y solo cambia en una fracción extremadamente insignificante de los datos. Ejemplo tenemos cartera de $10,000$ asegurados, $9,999$ son de Madrid y uno de CLM.

2.1. Preprocesamiento de los datos.

- 2.1.1. Etapas clave.
- 2.1.2. Deficiencias comunes en los datos.
- 2.1.3. ¿Qué hacer con los datos ausentes?.
- 2.1.4. Transformación variables categóricas.
- 2.1.5. Transformación variables continúas.

2.1.3. ¿Qué hacer con los datos ausentes (Missing Data)?

Tenemos cuatro opciones:

- Eliminación: descartas filas o columnas con datos ausentes, solo cuando sea alrededor de un 5 % del conjunto de datos.
- Imputación métrica: Sustituye todos los valores ausentes de una columna por un único valor estadístico global calculado con los datos disponibles de esa misma variabl, normalmente **media, mediana, moda, máximo o mínimo.**
- Imputación por vecinos más cercanos (K-nearest-Neighbors) (Fix and Hodges, 1951; Cover and Hart, 1967). Estima el valor ausente buscando los k registros (filas) más parecidos dentro de la base de datos, basándose en las variables que sí están completas.
- Imputación Múltiple por Ecuaciones Encadenadas (MICE - Multivariate Imputation by Chained Equations) (Rubin, 1987; van Buuren and Groothuis-Oudshoorn, 2011). Es una de las técnicas más robustas en la literatura científica. En lugar de rellenar el dato faltante una sola vez con un número fijo, MICE crea un modelo de regresión para cada variable con faltantes basándose en todas las demás variables. Además, genera múltiples conjuntos de datos imputados para incorporar la incertidumbre de la estimación.

2.1. Preprocesamiento de los datos.

- 2.1.1. Etapas clave.
- 2.1.2. Deficiencias comunes en los datos.
- 2.1.3. ¿Qué hacer con los datos ausentes?.
- 2.1.4. Transformación variables categóricas.
- 2.1.5. Transformación variables continúas.

2.1.4. Transformación variables categóricas.

Codificación Ordinal. En tarificación o modelado de siniestralidad, solemos trabajar con variables cualitativas (profesiones, marca del coche, código postal) que deben convertirse a números.

- Asigna un número entero consecutivo a cada categoría (ej. según orden alfabético).
- **Visión Data Science:** Fuerza una jerarquía inexistente. El modelo asumirá erróneamente que la profesión "4"dista el doble de la "2"sin justificación de riesgo.

Variable	Nº
Contable	1
Actuario	2
Economista	3
Quant (analista cuantitativo)	4
Estadístico	5
Consultor	6

2.1.4. Transformación variables categóricas.

One-Hot Encoding. Se podría argumentar que este orden no tiene mucho sentido y se deberían tratar estas variables como variables nominales.

Contable	1	0	0	0	0	0
Actuario	0	1	0	0	0	0
Economista	0	0	1	0	0	0
Quant (analista cuantitativo)	0	0	0	1	0	0
Estadístico	0	0	0	0	1	0
Consultor	0	0	0	0	0	1

- Crea una columna binaria (0 o 1) independiente para cada categoría.
- **Visión Data Science:** Trata las categorías como independientes. Es el estándar básico para algoritmos como árboles de decisión (decision trees) o redes neuronales (neural networks).

2.1.4. Transformación variables categóricas.

Dummy coding. One-hot encoding no lleva a una matriz completa de los datos, porque hay información redundante. Se elige un nivel que es incluido en el resto de las variables cuando sea zero, por ejemplo Actuario = 0.

Contable	1	0	0	0	0
Actuario	0	0	0	0	0
Economista	0	1	0	0	0
Quant (analista cuantitativo)	0	0	1	0	0
Estadístico	0	0	0	1	0
Consultor	0	0	0	0	1

- En la práctica se utiliza como variable dummy aquella con mayor exposición, es decir, el grupo de referencia de la columna.
- Evita la colinealidad perfecta (la suma de todas las columnas binarias daría 1).

2.1.4. Transformación variables categóricas.

Otros técnicas de preprocesamiento que implican uso de modelos de machine learning, para más información veáse Wüthrich et al. (2025):

- **Entity embedding**.
- **Target encoding**.

Ambos métodos se basan en sustituir cada categoría de una variable categórica por una estadística calculada a partir de la variable objetivo (target).

	Finanzas	Matemáticas	Estadística	Pensiones
Contable	0.5	0	0	0.5
Actuario	0.5	0.3	0.5	0.5
Economista	0.5	0.2	0.5	0
Quant (analista cuantitativo)	0.7	0.3	0.3	0
Estadístico	0	0.5	0.8	0
Consultor	0.3	0.3	0.3	0.1

Ejm. Entity embedding
$P(\text{Finanzas} = 1|\text{Actuario} = 1 = \text{Actuarios con conocimientos totales / Actuarios totales}$

2.1. Preprocesamiento de los datos.

- 2.1.1. Etapas clave.
- 2.1.2. Deficiencias comunes en los datos.
- 2.1.3. ¿Qué hacer con los datos ausentes?.
- 2.1.4. Transformación variables categóricas.
- 2.1.5. Transformación variables continúas.

2.1.5. Transformación variables continúas.

En teoría, este tipo de variables continuas (edad, suma asegurada, potencia vehículo, capital cubierto, etc.) se pueden usar directamente; en la práctica, la relación con el riesgo rara vez es estrictamente lineal. Por ello, existen tres opciones:

1. Ajuste de la Escala de Riesgo

- **Términos Cuadráticos / No Monótonos:** Capturan comportamientos en forma de "U" (ej. la siniestralidad en conductores jóvenes y muy mayores es alta, mientras que en edades medias disminuye).
- **Términos Exponenciales:** Capturan aceleraciones no lineales en el crecimiento de la severidad del siniestro.

2.1.5. Transformación variables continúas.

2. Estandarización.

El escalado asegura que covariables medidas en distintas unidades (ej. edad en años vs. salario en euros) no distorsionen el entrenamiento. Centra la variable en media 0 y desviación típica 1:

$$X \to \frac{X - \hat{\mu}}{\hat{\sigma}} \tag{1}$$

3. MinMaxScaler

Reescala los datos a un rango acotado de valores (ej. $[-1, 1]$ o $[0, 1]$). Esencial como paso previo antes de alimentar Redes Neuronales o funciones de activación acotadas:

$$X \to 2 \cdot \frac{X - \min_{1 \leq i \leq n} X_i}{\max_{1 \leq i \leq n} X_i - \min_{1 \leq i \leq n}} - 1 \tag{2}$$

2.1.5. Transformación variables continúas.

4. Logarítmos.

La transformación logarítmica ($\log(X)$ o $\log(Y)$) permite comprimir valores altos extremos (Ej. capitales asegurados) y es fundamental cuando las variables presentan asimetría positiva o variabilidad no constante (Hastie et al., 2009):

- **Estabilización de la varianza y corrección de asimetría:** Comprime valores extremos muy altos (ej. primas, capitales asegurados o cuantía de siniestros), aproximando la distribución a una Normal.
- **Interpretación semielástica y porcentual:**
  - Modelo $\log(Y) = \beta_0 + \beta_1 X$: Un incremento unitario en X produce un cambio relativo porcentual aproximado del $(100 \cdot \beta_1)\,\%$ en Y.
  - Modelo $\log(Y) = \beta_0 + \beta_1 \log(X)$ (log-log): Un incremento del $1\,\%$ en X se traduce en un cambio del $\beta_1\,\%$ en Y (elasticidad).



Ejemplo aplicado en R.

2.2. Modelos de Regresión Lineal

2.2. Modelos de Regresión Lineal.

- Notación.
- Definición.
- SSE.
- Log-Likelihood.
- Incorporar otros efectos - términos cualitativos, polinómicos, funciones splines, y `offset`.
- ¿Qué asume el modelo Lineal?

Notación.

$$\mathrm{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \tag{3}$$

X variable predictivas que utilizamos para predecir el comportamiento de Y, que es la variable respuesta cuantitativa.

Libros para profundizar en estos conceptos: regresión lineal, GLMs, modelos machine learning (boosting, decision trees, clustering, neural networks, etc.):



Vamos a suponer que partimos de que:

$$Y = f(X) + \varepsilon \tag{4}$$

Donde y es la variable es la variable respuesta o dependiente, $f(\cdots)$ corresponde con la forma en la que vamos a tratar de predecir el comportamiento de y, utilizando diferentes modelos (modelos lineales, GLMs, o machine learning) (Breiman, 2001; Antonio, 2023).



Regresión Lineal – Linear Regression

Def.: Se trata de un enfoque muy sencillo y lineal para predecir una respuesta cuantitativa Y a partir varias variables predictivas X (varias = Múltiple; 1 variable = Simple) mediante la función de regresión (James et al., 2015):

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p \cdot X_p + \varepsilon \tag{5}$$

donde: β_0 representa el `intercept` o constante y $\beta_1, \cdots, \beta_p$ son los `slope` o coeficientes de pendiente del modelo. Normalmente se les conoce como los parámetros del modelo.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_p \cdot X_p \tag{6}$$

ahora $\hat{y}$ indica la predicción que hacemos de Y, es decir, usamos $\hat{}$ para denotar el valor estimado de un parámetro desconocido.

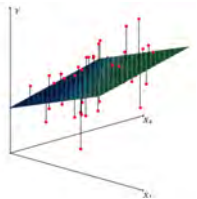
Regresión Lineal – Linear Regression

SSE

Nuestro objetivo es estimar los coeficientes de $\hat{\beta}_0, \hat{\beta}_1, \cdots, \hat{\beta}_p$ que consiguen que $Y \approx \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_p X_p$.

Para estimar estos coeficientes se utiliza una función de pérdidas `loss functions`. En regresión lineal, la más habitual es la **Suma de los Errores al Cuadrado** (*Sum of Squared Errors*, SSE), definida como:

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_n} \text{SSE} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} \left(y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_{i,1} + \cdots + \hat{\beta}_p \cdot x_{i,p} \right) \right)^2 \tag{7}$$



Regresión Lineal – Linear Regression

Log-Likelihood

Para estimar los coeficientes ($\theta = \hat{\beta}_0, \hat{\beta}_1, \cdots, \hat{\beta}_p$) la otra opción es usar la función de verosimilitud (`likelihood`), que se define como:

$$L(\theta) = \prod_{i=1}^{N} f(y_i; \theta), \tag{8}$$

donde $f(y_i; \theta)$ representa la densidad de probabilidad de cada observación. Dado que trabajar con productos resulta complicado, se utiliza la log-verosimilitud (`Log-Likelihood`). El estimador de máxima verosimilitud se obtiene resolviendo;

$$\hat{\theta} = \arg\max_{\theta} \ell(\theta) = \arg\max_{\theta} \log L(\theta) = \arg\max_{\theta} \sum_{i=1}^{N} \log f(y_i; \theta). \tag{9}$$

Regresión Lineal – Linear Regression

Log-Likelihood

Asumiendo que los errores se distribuyen como una normal $\varepsilon_i \sim N(0, \sigma^2)$. Bajo esta hipótesis estamos asumiendo que: $Y_i|X_i \sim N\left(\beta_0 + \beta_1 X_{i,1} + \cdots + \beta_p X_{i,p}, \sigma^2\right)$. De esta forma llegaríamos a la función de log-verosimilitud:

$$\arg\max_{\theta} \ell(\theta) = -\frac{N}{2}\log(2\pi) - N\log(\sigma) - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 . \tag{10}$$

siendo: N número total de observaciones, 2π es una constante, y σ es la desviación típica (siendo $\hat{\sigma}^2 = \text{SSE}(\beta)/N = \sum_{i=1}^{N}(y_i - \hat{y}_i)^2/N$).

Key concept:

Si los errores siguen una distribución Normal, estimar mediante Log-Verosimilitud es equivalente a minimizar SSE, (OLS).

Regresión Lineal – Linear Regression



Regresión Lineal – Linear Regression

```
Call:
lm(formula = prima ~ edad + bm + potencia + antiguedad + kms +
    capital)

Residuals:
     Min       1Q   Median       3Q      Max
-623.69 -100.76   -0.33  100.61  686.17

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.955e+02  4.290e+00   45.58   <2e-16 ***
edad         7.987e+00  2.594e-02  307.91   <2e-16 ***
bm           2.507e+01  1.492e-01  168.05   <2e-16 ***
potencia     2.014e+00  9.044e-03  222.65   <2e-16 ***
antiguedad  -3.066e+00  1.498e-01  -20.47   <2e-16 ***
kms          9.994e-03  1.583e-04   63.13   <2e-16 ***
capital      1.509e-02  9.406e-05  160.38   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 149.3 on 99993 degrees of freedom
Multiple R-squared:  0.6713,    Adjusted R-squared:  0.6712
F-statistic: 3.403e+04 on 6 and 99993 DF,  p-value: < 2.2e-16
```

Variables significativas

Coefcientes $\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_n$

Regresión Lineal – Linear Regression

Incoporar otros efectos - Transformar variables cualitativas

Recordar que las variables `edad`, `bm`, `potencia`, `antiguedad`, `kms`, y `capital` son numéricas. Si son variables cualitativas tendríamos que aplicar modificaciones:

- Variables con dos niveles $\rightarrow$ transformar en `dummy` (dicotómicas).
- Variables con más de dos niveles $\rightarrow$ crear una variable ficticia (`dummy`) menos que el número de niveles. Por ejemplo, variable `etnia`: asiático, caucásico y afroamericano.

$$x_{i,1} = \begin{cases} 1, & \text{si la persona } i \text{ es asiática,} \\ 0, & \text{si la persona } i \text{ no es asiática.} \end{cases} \tag{11}$$

Y la segunda variable indicadora correspondiente a la categoría *caucásico* puede definirse como:

$$x_{i,2} = \begin{cases} 1, & \text{si la persona } i \text{ es caucásica,} \\ 0, & \text{si la persona } i \text{ no es caucásica.} \end{cases} \tag{12}$$

Regresión Lineal – Linear Regression

Incoporar otros efectos - Términos Polinómicos e Interacciones

Para superar la rigidez del supuesto de linealidad pura, podemos transformar el espacio de entradas original (Hastie et al., 2009):

- **Polinomios de Grado Superior:** Añaden términos cuadráticos, cúbicos, etc., para capturar curvaturas y efectos no monótonos en la variable respuesta:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \cdots + \beta_d X_1^d + \varepsilon \tag{13}$$

  Ejemplo actuarial: La $\texttt{edad}^2$ del asegurado para capturar joroba accidentes.

- **Términos de Interacción:** Permiten que el efecto de una variable X_1 dependa del valor de otra variable X_2:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{1,2}(X_1 \cdot X_2) + \varepsilon \tag{14}$$

  Ejemplo actuarial: La interacción entre la `edad` del conductor y la `potencia` del vehículo.

Regresión Lineal – Linear Regression

Incoporar otros efectos - Expansión en Funciones Base y Splines

Modelamos relaciones complejas mediante combinaciones lineales de funciones base conocidas $h_k(X)$:

$$f(X) = \sum_{k=1}^{M} \beta_k h_k(X) \tag{15}$$

Tipos principales de funciones base:

- **Polinomios a trozos (*Piecewise Polynomials*):** Dividen el dominio de X mediante puntos de corte o nudos (`knots`), ajustando polinomios locales en cada tramo.
- **Splines Cúbicos Naturales:** Garantizan que las curvas en tramos adyacentes se unan de forma suave (con continuidad en las derivadas primera y segunda) y imponen linealidad fuera de los límites.
- **Funciones de Base Radial (RBF):** Basadas en distancias locales respecto a un centro.

Regresión Lineal – Linear Regression

Incoporar otros efectos - Concepto de `offset`

En datos actuariales y de seguros, la *exposición al riesgo* E (ej. tiempo de vigencia de la póliza, vehículos-año, tiempo de exposición al riesgo, etc.) es un dato real y conocido que determina el volumen de tiempo al que esta expuesto el riesgo a cubrir (Wüthrich et al., 2025).

Para garantizar la proporcionalidad respecto a la exposición real, el término de `offset` se incluye de forma fija en la escala logarítmica del modelo:

$$\begin{aligned} \log(Y) &= \underbrace{\log(E)}_{\text{offset}} + \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p, \\ Y &= E \cdot \exp\left(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p\right). \end{aligned} \tag{16}$$

El término $\log(E)$ entra en la ecuación con un coeficiente fijo igual a 1 (no se estima), garantizando la proporcionalidad estricta respecto a la exposición, que son los valores reales de los datos.

Regresión Lineal – Linear Regression

El modelo Lineal asume:

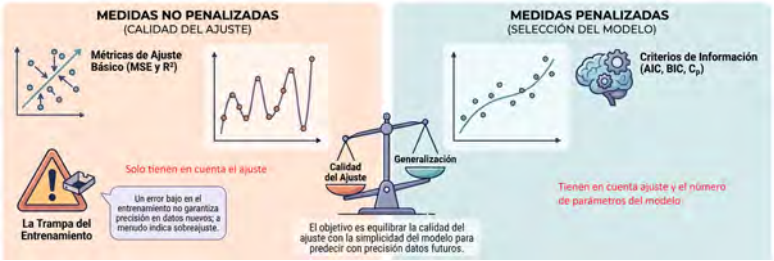
- Linealidad de los parámetros $E(Y|X) = X\beta$ o equivalente $E(\varepsilon_i|X) = 0$.
- Independencia entre los errores $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0; \qquad i \neq j$.
- Homocedasticidad: propiedad estadística en la que la varianza de los errores o de los residuos en un modelo de regresión es constante a lo largo de todas las observaciones o niveles de la variable independiente $\text{Var}(\varepsilon_i) = \sigma^2$.
- Normalidad de los residuos $\varepsilon_i \sim N(0, \sigma^2)$.
- Ausencia de colinealidad fuerte entre las variables.

2.3. Medidas de validación de modelos.

- 2.3.1. Medidas no penalizadas
- 2.3.2. Medidas penalizadas

2.3. Medidas de validación de modelos.

Def: las medidas de validación permiten cuantificar la calidad de un modelo y así poder comparar la capacidad de ajuste o predicción de los modelos utilizando criterios objetivos.



2.3.1. Medidas no penalizadas

Def.: Evalúan exclusivamente la calidad del ajuste del modelo, sin considerar el número de variables utilizadas.

Métrica	Fórmula	Objetivo
Suma de Cuadrados de los Errores (SSE)	$SSE = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$	mín
Error Cuadrático Medio (MSE)	$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$	mín
Raíz del Error Cuadrático Medio (RMSE)	$\text{RMSE} = \sqrt{MSE}$	mín
Error Absoluto Medio (MAE)	$MAE = \frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y}_i\rvert$	mín
Error Porcentual Absoluto Medio (MAPE)	$\text{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left\lvert\frac{y_i-\hat{y}_i}{y_i}\right\rvert$	mín
Coeficiente de Determinación (R^2)	$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}$	máx
Coeficiente de Determinación Ajustado (R^2_{adj})	$R^2_{adj} = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$	máx

Donde n es el número de datos y p número parámetros

2.3.1. Medidas no penalizadas

Existen otros tipos diferentes de coeficiente de determinación $\rightarrow R^2_{adj}$ (Yin and Fan, 2001):

- La fórmula arriba es el R^2_{adj} de Ezekiel/Wherry I: $R^2_{adj} = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$.
- R^2_{adj} de Olkin-Pratt $R^2_{adj} = 1 - \frac{n-3}{n-p-2}(1-R^2)\left[1 + \frac{2(1-R^2)}{n-p}\right]$.
- R^2_{adj} de Pratt $R^2_{adj} = 1 - \frac{(n-3)(1-R^2)}{n-p-1}\left[1 + \frac{2(1-R^2)}{n-p-2,3}\right]$

2.3.2. Medidas penalizadas

Def: Buscan un equilibrio entre: Calidad del ajuste + Complejidad del modelo.

Métrica / Criterio	**Fórmula**	**Objetivo**
Akaike Information Criterion (AIC)	$AIC = -2\,\ell(\hat{\theta}) + 2p$	**mín**
Bayesian Information Criterion (BIC)	$BIC = -2\,\ell(\hat{\theta}) + p\log(n)$	**mín**
AIC corregido (AIC_c)	$AIC_c = AIC + \frac{2p(p+1)}{n-p-1}$	**mín**
Hannan-Quinn Information Criterion (HQIC)	$HQIC = -2\,\ell(\hat{\theta}) + 2p\log(\log(n))$	**min**

Donde: p es el número total de parámetros estimados en el modelo (incluyendo el término independiente o intercepto y, si aplica, parámetros de escala/varianza como σ^2; y n número total de observaciones en el conjunto de datos (James et al., 2015).

Key concept:

Las medidas no penalizadas evalúan exclusivamente la calidad del ajuste, mientras que las penalizadas equilibran ajuste y complejidad, siendo especialmente útiles en procesos de selección automática de variables.



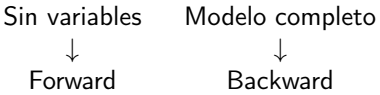
Ejemplo aplicado en R.

Forward and Backward stepwise.

2.4. Proceso de decisión Forward and Backward stepwise.

A la hora de decidir que variables queremos o no queremos incorporar en el modelo, surge el problema de ¿qué variables debemos incluir? selección a través del `p-value` asociado a cada coeficiente (variable).

El único problema es que introducir o eliminar una variable puede hacer cambiar el `p-value` del resto de las variables y empeora el criterio de ajuste. Además que este proceso de prueba/error puede llevar mucho tiempo. Es ahí donde surgen los métodos forward y backward stepwise (Efroymson, 1960) que son procedimientos para dar una solución automática (Hastie et al., 2009; James et al., 2015).

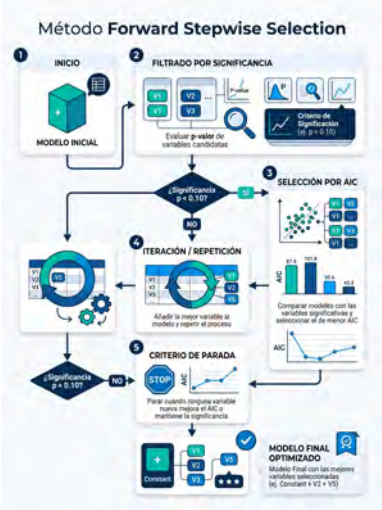


Proceso Forward Stepwise

Comenzamos con un modelo nulo/vacío (sin variables): $Y = \beta_0 + \varepsilon$, se van a incorporar una a una de las variables de forma iterativa.

Procedimiento:

1. Ajustar todos los $p - k$ modelos con una variable adicional (al comienzo solo habrá constante y variable extra).
2. Elegir una variable significativa (p-value < 0.10) que proporcione el mejor criterio (AIC, BIC o C_p).
3. Añadir dicha variable al modelo actual.
4. Repetir el proceso hasta que no exista una mejora significativa.



Proceso Backward Stepwise

Comenzamos con el modelo completo (con todas las variables): $Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$, y se van a eliminar variables una a una de forma iterativa.

Procedimiento:

1. Ajustar el modelo completo con todas las variables.
2. Eliminar la variable no significativa (`p-value` > 0.10) cuya eliminación produzca el menor deterioro (o la mayor mejora) en el criterio seleccionado (AIC, BIC).
3. Recalcular el criterio (AIC, BIC o AIC_c).
4. Repetir el proceso hasta que el criterio empeore.



2.4. Proceso de decisión Forward and Backward stepwise.



Ejemplo aplicado en R.

Cross-Validation

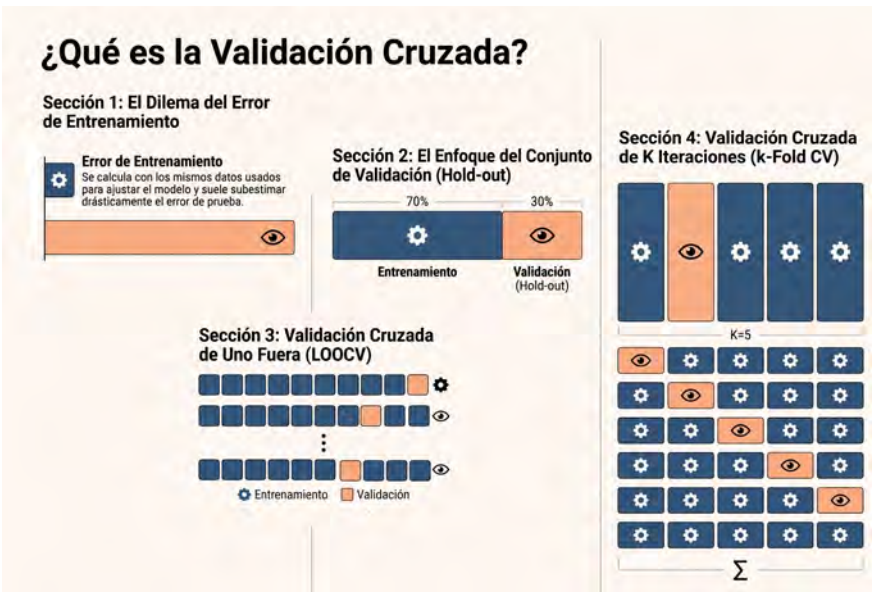
2.5. Cross-Validation.

Hasta ahora hemos ajustado y evaluado el modelo utilizando la misma muestra de datos. Esto puede llevar a una estimación demasiado optimista de la capacidad predictiva del modelo (Huang, 2026).

Un modelo puede adaptarse excesivamente bien a los datos de entrenamiento y obtener resultados mucho peores cuando se aplica sobre nuevas observaciones.

Key concept

La validación cruzada (cross-validation, CV) es una técnica de remuestreo que sirve para estimar la capacidad predictiva de un modelo utilizando datos no vistos (model assessment) (James et al., 2015) o para construir intervalos de confianza al recalibrar el modelo varias veces.


¿Qué es la Validación Cruzada?
Sección 1: El Dilema del Error de Entrenamiento
Error de Entrenamiento
Se calcula con los mismos datos usados para ajustar el modelo y suele subestimar drásticamente el error de prueba.
Sección 2: El Enfoque del Conjunto de Validación (Hold-out)
70%
30%
Entrenamiento
Validación (Hold-out)
Sección 3: Validación Cruzada de Uno Fuera (LOOCV)
Entrenamiento
Validación
Sección 4: Validación Cruzada de K Iteraciones (k-Fold CV)
K=5
Σ

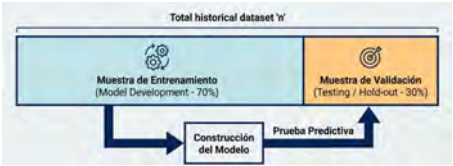
2.5.1. Test Fuera de muestra o Hold-out.

Def: El procedimiento consiste en dividir la muestra en dos partes (Lachenbruch and Mickey, 1968; Tashman, 2000):

- Training set: conjunto de entrenamiento y que se utiliza solo para entrenar el modelo (dentro de muestra).
- Testing set: conjunto para evaluar la capacidad predictiva del modelo.

La separación es 70 % y 30 % o 80 % y 20 %. Luego utilizaremos las medidas no penalizadas (penalizadas no se utilizan fuera de muestra) para evaluar la capacidad predictiva del modelo.

El único problema es que solo se evalúa la capacidad predictiva del modelo 1 sola vez.



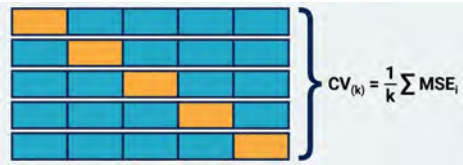
2.5.2. K-Fold-CV.

Def: La muestra se divide en K subconjuntos o bloques (Burman, 1989). Uno de los bloques se utiliza para validar y los restantes para entrenar. El proceso se repite hasta utilizar todos los bloques como conjunto de validación.

Como resultado del proceso, obtenemos k estimaciones independientes de la capacidad predictiva del modelo. La precisión global del modelo se calcula como el promedio de la medida de calidad obtenida en las k iteraciones:

$$\text{CV}_{(k)} = \frac{1}{k} \sum_{h=1}^{k} \text{Medida de bondad de ajuste}_h \tag{17}$$

donde Medida de bondad de ajuste$_h$ representa la métrica elegida (ej. MSE$_h$, RMSE$_h$, MAE$_h$) evaluada en el h-ésimo pliegue de validación. En la práctica, el número de subconjuntos o pliegues (*folds*) suele fijarse en $k = 5$ o $k = 10$.



2.5.3. Leave-One-Out-CV (LOOCV).

Def: En cada iteración: Una observación se utiliza como conjunto de validación y el resto de las observaciones $(n-1)$ se utilizan para entrenar el modelo (Burman, 1989; Shao, 1993). El proceso se repite n veces para que todas las observaciones se utilicen como conjunto de entrenamiento. La precisión del modelo se calcula como la media:

$$\text{LOO-CV}_{(n)} = \frac{1}{n}\sum_{i=1}^{n} \text{Medida de bondad de ajuste}_i \quad (18)$$

El procedimiento presenta dos ventajas: (1) El modelo se ajusta con prácticamente la totalidad de la muestra original, minimizando la sobreestimación del error de predicción. (2) Ausencia aleatoriedad, ya que todas las observaciones se utilizan de forma exhaustiva tanto para entrenar como para evaluar el modelo.





Ejemplo aplicado en R.

Puntos clave abordados en el Tema 2

- Preprocesamiento y calidad de los datos.
- Validación y selección de variables.
- Forward and backward stepwise.
- Cross-validation.

Key Concept

Todas estas técnicas las podemos replicar con todos los modelos que vamos a ver más adelante (GLMs).

Referencias I

Antonio, K. (2023). Hands on machine learning R module. Technical report, Github-repository. https://github.com/katrienantonio/hands-on-machine-learning-R-module-1.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Burman, P. (1989). A comparative study of ordinary cross–validation, v–fold cross-validation and the repeated learning-testing methods. *Biometrika*, 76(3):503–514.

Cover, T. and Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27.

Efroymson, M. A. (1960). Multiple regression analysis. In Ralston, A. and Wilf, H. S., editors, *Mathematical Methods for Digital Computers*, pages 191–203. Wiley.

Fix, E. and Hodges, J. L. (1951). Discriminatory analysis - nonparametric discrimination: Consistency properties. Technical Report 4, U.S. Air Force School of Aviation Medicine, Randolph Field, Texas.

Hastie, T., Tibshirani, R., Friedman, J. H., and Friedman, J. H. (2009). *The elements of statistical learning: data mining, inference, and prediction*, volume 2. Springer.

Huang, F. (2026). Actuarial data science: Open learning resource (v1.0.0). Technical report, Zenodo-repository. https://doi.org/10.5281/zenodo.20718647.

James, G., Witten, D., Hastie, T., and Tibshirani, R. (2015). *An Introduction to Statistical Learning: With Applications in R*. Springer, 6 edition. Corrected 6th printing.

Kuhn, M. and Johnson, K. (2013). *Applied predictive modeling*. Springer, New York.

Lachenbruch, P. A. and Mickey, M. R. (1968). Estimation of error rates in discriminant analysis. *Technometrics*, 10(1):1–11.

Mahalanobis, P. C. (1936). On the generalised distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1):49–55.

Referencias II

Rubin, D. B. (1987). *Multiple imputation for nonresponse in surveys*. John Wiley & Sons, New York.

Shao, J. (1993). Linear model selection by cross–validation. *Journal of the American Statistical Association*, 88(422):486–494.

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4):437–450.

van Buuren, S. and Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3):1–67.

Wüthrich, M. V., Richman, R., Avanzi, B., Lindholm, M., Maggi, M., Mayer, M., Schelldorfer, J., and Scognamiglio, S. (2025). AI tools for actuaries. *SSRN Manuscript*. http://dx.doi.org/10.2139/ssrn.5162304.

Yin, P. and Fan, X. (2001). Estimating r^2 shrinkage in multiple regression: A comparison of analytical methods. *The Journal of Experimental Education*, 69(2):203–224.

MATERIAL DOCENTE

Autoría

David Atance del Olmo

Departamento de Economía y Dirección de Empresas
Universidad de Alcalá

CC BY-NC-SA 4.0

© 2026 David Atance del Olmo

Este material se distribuye bajo la licencia Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional.

Consultar la licencia CC BY-NC-SA 4.0