SIMULACIÓN Y MODELOS PARA EL ANÁLISIS DE DATOS ACTUARIALES Y FINANCIEROS

Departamento de Economía y Dirección de Empresas.

Máster en Ciencias Actuariales y Financieras.

Profesor: **David Atance del Olmo**

david.atance@uah.es



Departamento Economía
y Dirección de Empresas
UAH

Conceptos a tratar en la asignatura

Hoja de Ruta: Simulación y Modelos para el Análisis Actuarial

Parte I - Simulación de Variables (Semanas 1-2) | **Parte II - Modelos de Regresión y Machine Learning (Semanas 3-14)**

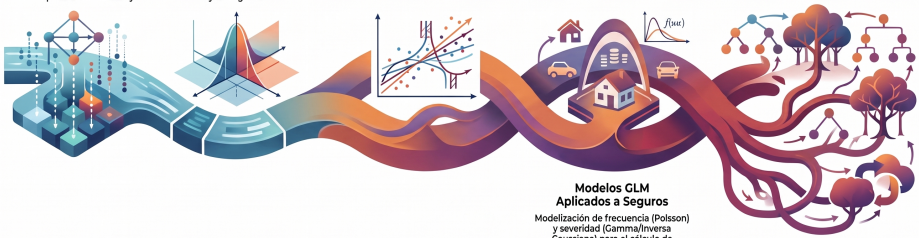
Generación de Variables Aleatorias
Creación de variables individuales y multivariantes mediante generadores de números y la descomposición de Cholesky.

Distribución Normal y Multivariante
Técnicas específicas para simular comportamientos normales complejos en entornos financieros y de seguros.

Regresión Lineal y Regularización (Lasso, Ridge, Elastic-Net)
Técnicas de proprocesamiento, validación cruzada y selección de variables para evitar el sobreajuste.

Modelos GLM Aplicados a Seguros
Modelización de frecuencia (Poisson) y severidad (Gamma/Inversa Gaussiana) para el cálculo de primas y reservas.

Introducción al Machine Learning Actuarial
Implementación de árboles de decisión, Random Forest y Boosting para la predicción de riesgos.

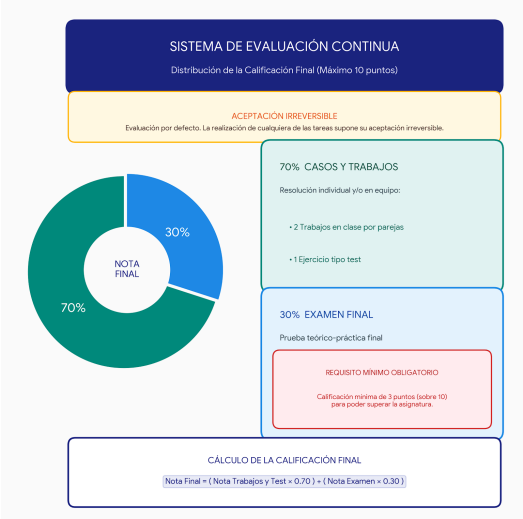


Modelos GLM Aplicados a Seguros
Modelización de frecuencia (Poisson) y severidad (Gamma/Inversa Gaussiana) para el cálculo de primas y reservas.

Cronograma de dedicación por bloques temáticos del curso

I. Simulación (Tema 1) | 2 Semanas | II. Regresión Lineal (Temas 4 y 5) | 5 Semanas | II. Modelos GLM y ML (Temas 6, 7, 8, 9 y 10) | 7 Semanas

Conceptos a tratar en la asignatura



Tema 3:
Métodos de Regularización.

Guía Rápida de Regularización: Ridge, LASSO y Elastic Net

Los Tres Estimadores Principales



Ridge Regression (Penalización ℓ_2)

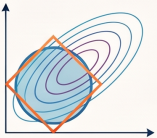


LASSO (Penalización ℓ_1)



Elastic Net (Penalización Híbrida)

Diferencias Visuales y Geométricas



Forma de la Restricción (Elipses vs. Diamantes)

LASSO (diamante) puede tocar los ejes y anular variables; Ridge (círculo) no.

Gestión de la Correlación





LASSO selecciona una variable de un grupo correlacionado; Ridge y Elastic Net distribuyen el peso equilibradamente.

¿Cómo seleccionar el mejor método?



Escenario para LASSO: Escasez



Escenario para Ridge: Muchos Predictores



Escenario para Elastic Net: Alta Dimensión y Grupos

Índice

- 3.1. Introducción del problema.
- 3.2. Ridge estimador.
- 3.3. LASSO estimador.
- 3.4. Elastic Net.
- 3.5. Como seleccionar entre ellos.

3.1. Introducción del problema.

- 3.1.1. Dificultad del problema.
- 3.1.2. Overfitting.
- 3.1.3. Sesgo-Varianza (Bias-variance).
- 3.1.4. Idea general de la regularización

3.1.1. Dificultad del problema.

Queremos aproximar la relación entre una variable respuesta Y y un conjunto de variables predictivas X:

$$Y = f(X) + \varepsilon \tag{1}$$

Nuestro objetivo consiste en encontrar una función $\hat{f}(X)$ capaz de predecir correctamente nuevas observaciones.

La calidad del ajuste suele medirse mediante la suma de cuadrados de los residuos (SSE):

$$SSE(f) = \sum_{i=1}^{N} (y_i - f(x_i))^2 . \tag{2}$$

3.1.1. Dificultad del problema.

Supongamos que conocemos la verdadera relación: $Y = f(X) + \varepsilon$ y construimos un predictor $\hat{f}(X)$.

El error de predicción puede descomponerse en:

$$E\left[(Y - \hat{f}(X))^2\right] = \underbrace{\left(f(X) - \hat{f}(X)\right)^2}_{\text{Error reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{Error irreducible}}, \tag{3}$$

- El **error reducible** depende de la calidad del modelo utilizado.
- El **error irreducible** proviene del ruido inherente a los datos.

Aunque conociéramos exactamente la función $f(X)$ seguiría existiendo un error asociado al término aleatorio ε.

3.1.1. Dificultad del problema.

Si existe un término aleatorio: $\varepsilon \neq 0$ entonces las variables explicativas X nunca podrán explicar perfectamente la variable respuesta Y.

Por tanto, el objetivo real no consiste en eliminar completamente el error, sino en minimizar la parte del error que sí podemos controlar: Error Reducible (Hastie et al., 2015; James et al., 2015; Antonio, 2023).

Mejor ajuste posible

$\neq$

Predicción perfecta.

3.1.1. Dificultad del problema.

Existen muchas diferentes funciones $f(\cdot)$ para minimizar la SSE:

$$SSE(f) = \sum_{i=1}^{N} (y_i - f(x_i))^2 . \tag{4}$$

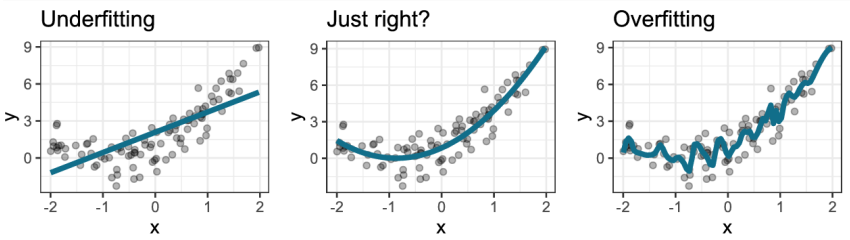
De hecho, todas las funciones que pasen exactamente por los puntos observados producirán: $SSE = 0$.

Sin embargo, obtener un "excelente" error dentro de muestra no garantiza buenos resultados fuera de la muestra observada (Antonio, 2023).

3.1.2. Overfitting.

Un modelo excesivamente flexible puede conseguir:

- Ajustar los datos perfectamente.
- Ajustar el ruido aleatorio presente en la muestra.



Recordar que el MODELO que busca obtener tiene que predecir (o ajustarse) lo mejor posible fuera de muestra (información no vista) (Antonio, 2023).

3.1.3. Sesgo-Varianza (Bias-variance).

Reducir la complejidad del modelo suele aumentar ligeramente el sesgo, pero puede reducir significativamente la varianza del estimador.

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{N}\left(y_i - f\left(x_i\right)\right)^2. \tag{5}$$

y ahora si tomamos la esperanza de MSE tenemos:

$$E\left(y_i - f\left(x_i\right)\right)^2 = \text{Var}\left(\hat{f}\left(x_0\right)\right) + \left[\text{Bias}\left(\hat{f}\left(x_0\right)\right)\right]^2 + \text{Var}\left(\varepsilon\right)$$

Cuando busquemos minimizar el error medio esperado necesitamos encontrar un modelo que simultaneamente minimice la *varianza* y el *sesgo* del modelo (`Bias` y `Var`)

- Modelos muy complejos: baja sesgo, alta varianza.
- Modelos muy simples: alto sesgo, baja varianza.
- El objetivo es encontrar un equilibrio adecuado.

3.1.4. Idea general de la regularización

En lugar de minimizar únicamente $SSE(\beta)$, se va a introducir una penalización al modelo, que restringe o regulariza las estimaciones de los coeficientes o, lo que es lo mismo, que reduce (*shrinks*) las estimaciones de los coeficientes hacia cero (Tibshirani et al., 2005).

$$\underbrace{SSE(\beta)}_{\text{Calidad del ajuste}} + \underbrace{\text{Penalización}}_{\text{Complejidad}} \tag{6}$$

Existen diferentes métodos de penalización:

- Ridge.
- LASSO.
- Elastic Net.

3.2. Ridge estimator.

- 3.2.1. Definición.
- 3.2.2. Interpretación geométrica.
- 3.2.3. Efecto de λ.

Key concept

El estimador Ridge incorpora una penalización sobre el tamaño de los coeficientes con el objetivo de reducir la complejidad del modelo y mejorar su capacidad predictiva.

3.2. Ridge estimator.

¿Qué hace de forma sencilla Ridge?

- Ridge asume inicialmente que todas las variables pueden contener información útil.
- En lugar de eliminar variables (como hacemos en el proceso stepwise forward o backward), mantiene todas dentro del modelo, pero reduce progresivamente el tamaño de sus coeficientes.
- Así, se obtienen estimaciones más estables, se reduce el riesgo de sobreajuste y se consigue mejorar la capacidad predictiva de los modelos fuera de muestra.

3.2.1. Definición.

Recordamos que OLS se pueden estimar los parámetros mediante:

$$\min_{\beta} SSE(\beta) = \min_{\beta} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \min_{\beta} \sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 \cdot X_1 + \cdots + \beta_p \cdot X_p))^2 . \tag{7}$$

El estimador Ridge (Hoerl and Kennard, 1970) añade una penalización cuadrática sobre los coeficientes:

$$\min_{\beta} \left\{ \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j \cdot x_{i,j} \right)^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \right\} = \min_{\beta} \left[SSE(\beta) + \underbrace{\lambda \sum_{j=1}^{p} \beta_j^2}_{\text{shrinkage penalty}} \right] . \tag{8}$$

donde:

- $\lambda \geq 0$ sirve para controlar el impacto relativo de estos dos términos en las estimaciones de los coeficientes de regresión.
- Solo se penaliza $\beta_1, \beta_2, \cdots, \beta_p$ pero no el intercepto β_0 (media simple de las variables respuestas cuando $x_{i,1} = x_{i,2} = \cdots = x_{i,p} = 0$). Aunque, se podría penalizar el intercepto (β_0.

3.2.1. Definición.

$$\min_{\beta} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j \cdot x_{i,j} \right)^2 = \min_{\beta} \left[SSE(\beta) + \underbrace{\lambda \sum_{j=1}^{p} \beta_j^2}_{\text{shrinkage penalty}} \right]. \tag{9}$$

Interpretación:

- Un modelo complejo suele producir coeficientes grandes.
- Ridge penaliza dichos coeficientes ($\beta_1, \beta_2, \cdots, \beta_p$, pero se queda fuera del suavizado el intercepto β_0).
- La estimación final busca un equilibrio entre:

La metodología Ridge se puede aplicar también para penalizar la Log-Likelihood.

3.2.1. Definición. Sol analítica

Recordemos que:

$$\hat{\beta}_{OLS} = (X'X)^{-1}X'Y. \tag{10}$$

El estimador Ridge viene dado por la siguiente resolución matricial:

$$\hat{\beta}_{Ridge} = (X'X + \lambda I)^{-1}X'Y. \tag{11}$$

- Siempre existe incluso cuando existe multicolinealidad.
- Introduce estabilidad en las estimaciones.
- Reduce la varianza de los coeficientes.

3.2.2. Interpretación geométrica.

La formulación Ridge puede escribirse de forma equivalente como: $\min_\beta SSE(\beta)$, sujeta a la restricción $\sum_{j=1}^{p} \beta_j^2 \leq t$, para alguna constante $t > 0$.

Por lo que La región admisible viene dada por: $\beta_1^2 + \beta_2^2 \leq t$ que geométricamente corresponde a un círculo (o esfera en dimensiones superiores) (Hastie et al., 2015).

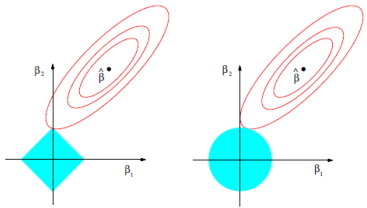


Figure 2.2 *Estimation picture for the lasso (left) and ridge regression (right).*

3.2.2. Interpretación geométrica.

- Las elipses representan niveles constantes de SSE.
- El círculo representa la restricción Ridge.
- La solución óptima aparece en el primer punto de tangencia.

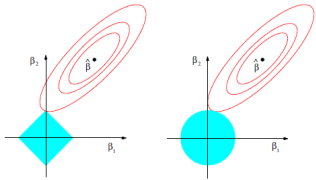


Figure 2.2 *Estimation picture for the lasso (left) and ridge regression (right).*

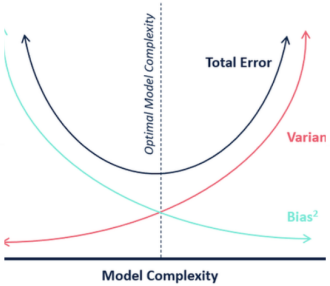
Key concept

El estimador Ridge reduce simultáneamente todos los coeficientes, pero raramente los convierte exactamente en cero.

3.2.3. Efecto de λ.

El parámetro λ controla la intensidad de la penalización.

$$\min_{\beta} \left[SSE(\beta) + \lambda \sum_{j=1}^{p} \beta_j^2 \right]. \qquad (12)$$



- $\lambda = 0 \Rightarrow$ recuperamos OLS.
- $\lambda > 0 \Rightarrow$ los coeficientes comienzan a reducirse.
- $\lambda \to \infty \Rightarrow$ los coeficientes tienden a cero.

3.2.3. Efecto de λ.

Ventajas

- Reduce el sobreajuste.
- Funciona bien en presencia de multicolinealidad.
- Produce estimaciones más estables.

Inconvenientes

- No realiza selección automática de variables.
- Todos los coeficientes permanecen en el modelo.



Ejemplo aplicado en R.

3.3. LASSO estimator.

Desglose:

- 3.3.1. Definición.
- 3.3.2. Interpretación geométrica.
- 3.3.3. Propiedad fundamental

Key concept

El estimador LASSO incorpora una penalización diferente de los parámetros en comparación con ridge. Además busca reducir la varianza de los estimadores, y fuerza a que los coeficientes sean e iguales a cero, realizando una selección automática de variables (Hastie et al., 2015; James et al., 2015).

3.3. LASSO estimator.

¿Qué hace de forma sencilla LASSO?

- LASSO estima simultáneamente los coeficientes y selecciona las variables más relevantes para explicar la variable respuesta.
- Reduce el tamaño de los coeficientes estimados y puede forzar algunos de ellos a ser exactamente iguales a cero (auto selección).
- Genera modelos más simples, más interpretables y con una mejor capacidad predictiva fuera de muestra.

3.3.1. Definición.

El estimador LASSO (*Least Absolute Shrinkage and Selection Operator*) (Tibshirani, 1996) sustituye la penalización cuadrática ℓ_2 de Ridge por una penalización ℓ_1 basada en el valor absoluto de los coeficientes:

$$\min_{\beta} \left\{ \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j \cdot x_{i,j} \right)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \right\} = \min_{\beta} \left[SSE(\beta) + \underbrace{\lambda \sum_{j=1}^{p} |\beta_j|}_{\text{shrinkage penalty}} \right]. \tag{13}$$

donde:

- $\sum_{j=1}^{p} |\beta_j|$ representa la penalización del vector de coeficientes (Wüthrich et al., 2025).
- $\lambda \geq 0$ controla la intensidad de la penalización (al igual que en Ridge) (Hastie et al., 2015).
- No existe solución analítica cerrada en forma matricial debido a la no diferenciabilidad de la penalización en el origen (0) (Antonio, 2023). Su optimización requiere métodos numéricos convexos (e.g., "*coordinate descent*") (Hastie et al., 2015).

3.3.1. Definición.

- Recordemos que el estimador Ridge utilizaba una penalización de tipo: $\sum_{j=1}^{p} \beta_j^2$.
- Mientras que LASSO sustituye esta penalización por: $\sum_{j=1}^{p} |\beta_j|$.
- ¿Qué diferencia un método de otro?
  - Ambos métodos reducen la magnitud de los coeficientes.
  - Ridge produce coeficientes pequeños.
  - LASSO puede producir coeficientes exactamente nulos (auto-selección).

Key concept

La principal diferencia entre Ridge y LASSO es que este último puede eliminar variables completas del modelo.

3.3.1. Definición.

Comparación entre modelos Ridge versus LASSO.

Característica	Ridge	LASSO
Penalización	ℓ_2	ℓ_1
Reduce coeficientes	Sí	Sí
Selección automática	No	Sí
Coeficientes nulos	Raramente	Frecuentemente
Interpretabilidad	Media	Alta

En modelos con muchas variables explicativas, LASSO suele proporcionar soluciones más fáciles de interpretar.

3.3.1. Definición.

A diferencia de MCO (OLS), el estimador LASSO depende de la escala en la que están medidas las variables predictoras (Hastie et al., 2015):

$$\min_{\beta} \left[SSE(\beta) + \lambda \sum_{j=1}^{p} |\beta_j| \right] \tag{14}$$

- Si una variable X_1 se mide en euros y X_2 en millones de euros, β_1 será muy pequeño y β_2 muy grande, sufriendo penalizaciones dispares (Hastie et al., 2015).
- Por ello, Antes de estimar LASSO, todas las covariables deben *centrarse y escalarse* (standarization) (Hastie et al., 2015; James et al., 2015):

$$\tilde{x}_{i,j} = \frac{x_{i,j} - \bar{x}_j}{\hat{\sigma}_j}, \quad \text{de forma que} \quad \frac{1}{n}\sum_{i=1}^{n} \tilde{x}_{i,j} = 0 \quad \text{y} \quad \frac{1}{n}\sum_{i=1}^{n} \tilde{x}_{i,j}^2 = 1. \tag{15}$$

- Esto garantiza que el término de intercepto $\beta_0 = \bar{y}$ pueda omitirse durante la optimización y recomputarse al final (Hastie et al., 2015; Denuit et al., 2019).

3.3.1. Definición.

A diferencia de Ridge, la función objetivo de LASSO no es diferenciable en $\beta_j = 0$. Por ello no es posible obtener una solución matricial analítica similar a $(X'X + \lambda I)^{-1}X'Y$.

Por ello, se utilizan procedimientos iterativos, el algoritmo estándar (*Cyclic Coordinate Descent*) resuelve el problema mediante optimización unidimensional iterativa (Hastie et al., 2015; Antonio, 2023):

Algoritmo Descenso por Coordenadas Cíclico:

1. Se fija un valor inicial para todos los coeficientes $\hat{\beta}_1, \ldots, \hat{\beta}_p$.
2. Para cada predictor $j = 1, \ldots, p$, se calcula el residuo parcial $r_i^{(j)} = y_i - \sum_{k \neq j} x_{i,k}\hat{\beta}_k$.
3. Se actualiza únicamente el coeficiente $\hat{\beta}_j$ aplicando el operador de umbralización suave (*soft-thresholding*) sobre la regresión del residuo parcial (Hastie et al., 2015):

$$\hat{\beta}_j \leftarrow S_{\lambda/2}\left(\frac{1}{n}\sum_{i=1}^{n} x_{i,j} r_i^{(j)}\right) \tag{16}$$

4. Se repite el ciclo sobre todas las variables hasta la convergencia global del algoritmo (Hastie et al., 2015).

3.3.2. Interpretación geométrica.

De forma equivalente al problema con penalización, LASSO puede formularse como un problema de optimización restringido (James et al., 2015):

$$\min_{\beta} SSE(\beta) \quad \text{sujeto a} \quad \sum_{j=1}^{p} |\beta_j| \leq s, \quad \text{para algún } s > 0. \tag{17}$$

Geométricamente:

- Para $p = 2$, la región admisible dada por $|\beta_1| + |\beta_2| \leq s$ es un "diamante" (rombo) (James et al., 2015).
- En dimensiones superiores ($p \geq 3$), esta región forma un "poliedro" con vértices y aristas afiladas en los ejes coordenados (Hastie et al., 2015; James et al., 2015).

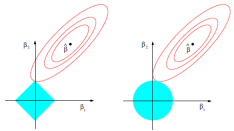


Figure 2.2 *Estimation picture for the lasso (left) and ridge regression (right).*

3.3.2. Interpretación geométrica.

Puntos clave de la solución óptima:

- Las elipses rojas representan contornos de constante *SSE* centrados en la solución de OLS ($\hat{\beta}_{OLS}$) (James et al., 2015).
- El punto de contacto entre la elipse de *SSE* y la región de restricción ocurre frecuentemente en un "vértice" o "esquina" del diamante (sobre uno de los ejes) (James et al., 2015).
- Cuando la tangencia ocurre en un vértice, el coeficiente correspondiente a ese eje es exactamente cero ($\beta_j = 0$) (Hastie et al., 2015; James et al., 2015).

Key concept.

Diferencia geométrica fundamental. Ridge usa un círculo suave (sin esquinas), provocando tangencias fuera de los ejes ($\beta_j \neq 0$). LASSO posee vértices en los ejes, anulando variables de forma efectiva (James et al., 2015; Denuit et al., 2019; Antonio, 2023).

3.3.2. Interpretación geométrica.

¿Por qué aparecen coeficientes iguales a cero?

- La región de restricción LASSO posee vértices localizados sobre los ejes coordenados: $(\beta_1, 0), \quad (0, \beta_2)$.
- Las curvas de nivel del SSE tienden a coincidir en los vértices con elevada frecuencia.
- Cuando esto ocurre: $\beta_j = 0$. Por tanto, la variable asociada desaparece del modelo.

3.3.3. Propiedad fundamental

Supongamos que al aplicar OLS obtenemos:

$$\hat{\beta}^{OLS} = (3{,}5,\ 2{,}1,\ 0{,}4,\ 0{,}1,\ -0{,}05).$$

Mientras que después de aplicar LASSO llegamos a:

$$\hat{\beta}^{LASSO} = (2{,}8,\ 1{,}7,\ 0,\ 0,\ 0).$$

Las tres últimas variables son eliminadas automáticamente por el procedimiento LASSO. El modelo conserva únicamente las variables con mayor capacidad explicativa.

3.3.3. Propiedad fundamental

1. Sparsity[a] y Selección Automática de Variables:
   - LASSO actúa como un operador de reducción y selección (*Least Absolute Shrinkage and Selection Operator*) (Hastie et al., 2015).
   - Genera sparse models[b], facilitando la interpretabilidad en problemas de alta dimensión ($p > n$) (Hastie et al., 2015; James et al., 2015).

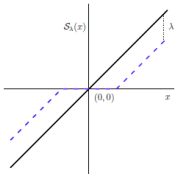


Figure 2.4 *Soft thresholding function* $S_\lambda(x) = \text{sign}(x)(|x| - \lambda)_+$ *is shown in blue (broken lines), along with the* $45°$ *line in black.*

[a] Def: es una propiedad en inteligencia artificial y matemáticas donde una matriz o tensor contiene una proporción muy elevada de valores cero

[b] es aquel en el que la gran mayoría de sus parámetros, coeficientes o pesos son exactamente cero o insignificantes, activando o utilizando solo una pequeña fracción de su capacidad total para cada tarea o cálculo

3.3.3. Propiedad fundamental

Efecto de λ:

- $\lambda = 0$ recupera la solución OLS.
- A medida que aumenta λ los coeficientes se reducen.
- Algunos coeficientes alcanzan exactamente el valor cero (auto-selección).
- Valores elevados de λ generan modelos muy parsimoniosos.

$$\text{Mayor } \lambda \Longrightarrow \text{Menos variables seleccionadas}$$

3.3.3. Propiedad fundamental

Ventajas

- Reduce el sobreajuste.
- Realiza selección automática de variables.
- Produce modelos más interpretables.
- Puede aplicarse cuando $p > n$.
- Resulta especialmente útil cuando existen cientos o miles de variables explicativas.

Inconvenientes

- Puede resultar inestable cuando existen variables altamente correlacionadas.
- Tiende a seleccionar una variable y descartar el resto del grupo.
- No siempre proporciona la mejor capacidad predictiva.

3.3.3. Propiedad fundamental

Limitación de LASSO:

- Cuando varias variables presentan una fuerte correlación, $\text{Corr}(X_i, X_j) \approx 1$.
- LASSO suele seleccionar únicamente una de ellas y eliminar las restantes (Zou and Hastie, 2005; Huang, 2026).

¿Se puede combinar las ventajas de los métodos Ridge y LASSO?

$$\Downarrow$$

Elastic Net



Ejemplo aplicado en R.

3.4. Elastic-Net.

- 3.4.1. Definición.
- 3.4.2. Papel de α y λ.
- 3.4.3. Propiedad fundamental.

Key concept

Elastic Net combina las ventajas de Ridge y LASSO en un único procedimiento de estimación, permitiendo simultáneamente reducir coeficientes y seleccionar variables.

3.4.1. Definición.

Elastic Net combina las ideas fundamentales de Ridge y LASSO (Zou and Hastie, 2005; Hastie et al., 2015).

- Ridge reduce todos los coeficientes pero mantiene todas las variables.
- LASSO reduce coeficientes y elimina variables.
- Elastic Net realiza ambas tareas simultáneamente.

Este enfoque resulta especialmente útil cuando existen grupos de variables altamente correlacionadas.

3.4.1. Definición.

Definición: Elastic Net combina las penalizaciones Ridge y LASSO en una única función objetivo:

$$\min_{\beta} \left[\sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j \cdot x_{i,j} \right)^2 + \lambda \left((1-\alpha) \sum_{j=1}^{p} \beta_j^2 + \alpha \sum_{j=1}^{p} |\beta_j| \right) \right] =$$

$$\min_{\beta} \left[SSE(\beta) + \lambda \left(\underbrace{(1-\alpha) \sum_{j=1}^{p} \beta_j^2}_{\text{Ridge}} + \underbrace{\alpha \sum_{j=1}^{p} |\beta_j|}_{\text{LASSO}} \right) \right] \tag{18}$$

donde:

- $\lambda \geq 0$ es el **parámetro de regularización** que controla la intensidad global de la penalización (cuanto mayor es λ, mayor es el encogimiento de los coeficientes hacia cero).
- $\alpha \in [0, 1]$ determina el peso relativo entre Ridge y LASSO.

3.4.1. Definición.

La función objetivo puede interpretarse como:

$$\text{Ajuste } [SSE(\beta)] + \lambda \cdot (\text{Penalización Ridge} + \text{Penalización LASSO}) \tag{19}$$

El papel del hiperparámetro λ:

- $\lambda = 0$: No hay penalización; el modelo equivale a la estimación por OLS.
- $\lambda > 0$: Introduce penalización, contrayendo los coeficientes hacia cero para reducir la varianza del estimador.
- $\lambda \to \infty$: La penalización domina y todos los coeficientes se reducen a cero (quedando solo el intercepto β_0).

Elastic Net busca simultáneamente minimizar el error de ajuste y controlar la complejidad mediante el nivel de penalización λ.

3.4.2. Papel de α y λ.

El parámetro α permite introducir la penalización de ambos procesos de penalización Ridge y LASSO:

$$\begin{aligned} \alpha = 0 &\Longrightarrow \text{Ridge Regression (penalización } \ell_2) \\ \alpha = 1 &\Longrightarrow \text{LASSO (penalización } \ell_1) \\ 0 < \alpha < 1 &\Longrightarrow \text{Elastic Net (combinación de ambos procedimientos)} \end{aligned}$$

Relación entre ambos hiperparámetros:

- α dicta la penalización que se aplica.
- λ permite establecer cuánta penalización se aplica globalmente sobre el modelo.
- Si $\alpha \to 1$: el modelo favorece la *sparsity* (auto-selección de variables).
- Si $\alpha \to 0$: el modelo favorece el agrupamiento y la estabilidad ante multicolinealidad.
- La pareja óptima (α, λ) se selecciona conjuntamente mediante una búsqueda en rejilla con Validación Cruzada (CV).

3.4.2. Papel de α y λ.

$$\text{Ridge} \quad \alpha = 0 \quad \Longleftrightarrow \quad \text{Elastic Net} \quad \Longleftrightarrow \quad \alpha = 1 \quad \text{LASSO.} \tag{20}$$

A medida que α aumenta:

- La selección automática de variables se vuelve más intensa.
- El comportamiento se aproxima progresivamente a LASSO.

3.4.3. Propiedad fundamental.

Elastic Net es especialmente útil cuando varias variables presentan una fuerte correlación: $\text{Corr}(X_i, X_j) = \rho(X_i, X_j) \approx 1$

En estas situaciones:

- LASSO suele seleccionar una única variable y eliminar las demás.
- Ridge mantiene todas las variables.
- Elastic Net suele seleccionar conjuntamente grupos de variables correlacionadas.

3.4.3. Propiedad fundamental.

Ejemplo conceptual. Supongamos tres variables muy correlacionadas:
$X_1 = \text{Capital}, \quad X_2 = \text{Capital asegurado}, \quad X_3 = \text{Valor del vehículo}.$

- Ridge mantendrá las tres variables.
- LASSO puede conservar únicamente una.
- Elastic Net tiende a seleccionar las tres conjuntamente.

Esto produce modelos más estables ante pequeños cambios en la muestra.

3.4.3. Propiedad fundamental.

Ventajas

- Reduce el sobreajuste.
- Gestiona adecuadamente la multicolinealidad.
- Realiza selección automática de variables.
- Funciona bien en problemas de alta dimensión.

Inconvenientes

- Deben seleccionarse dos parámetros (λ y α).
- Mayor coste computacional.
- Menor simplicidad interpretativa que Ridge o LASSO por separado.



Ejemplo aplicado en R.

El problema práctico

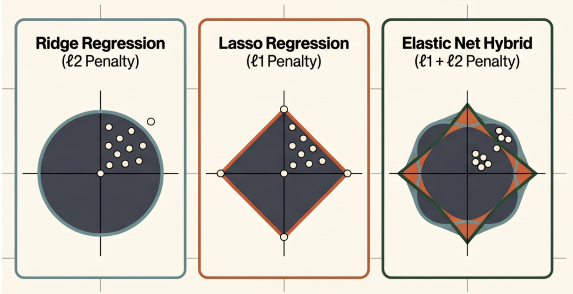
A lo largo del tema hemos presentado tres alternativas:

- Ridge.
- LASSO.
- Elastic Net.

Además, cada modelo depende de uno o varios hiperparámetros:

- Ridge: λ.
- LASSO: λ.
- Elastic Net: (λ, α).

Pero de todos ellos, ¿cuál proporciona mejores resultados y como elegimos los hiperparámetros?.



3.5. ¿Cómo seleccionar entre ellos?

- 3.5.1. Validación Cruzada.
- 3.5.2. Comparación de errores
- 3.5.3. ¿Qué modelo elegir?

Key concept

La selección del modelo óptimo (Ridge, LASSO o Elastic Net) y la elección de sus hiperparámetros (λ y α) no debe realizarse sobre los datos de entrenamiento. Sino mediante Cross-Validation y en datos no vistos (out-of-sample, fuera de muestra) (Hastie et al., 2015; James et al., 2015).

3.5.1. Validación Cruzada (K-Fold Cross-Validation).

Para calibrar el hiperparámetro de penalización λ (o la rejilla 2D (α, λ) en Elastic Net), se divide la muestra de entrenamiento en K subconjuntos (*folds*) disjuntos (James et al., 2015):

1. Para un valor de λ en una rejilla prefijada:
   - Se entrena el modelo en $K-1$ subconjuntos.
   - Se evalúa una métrica de error (MSE, MAE, Devianza, ...) en el subconjunto reservado k.
2. Se promedia la métrica de error tras utilizar todos los subconjuntos $k = 1, \ldots, K$ como validación (James et al., 2015):

$$CV_{(\lambda)} = \frac{1}{K} \sum_{k=1}^{K} MSE_k(\lambda) \tag{21}$$

3. Calibración en Elastic Net: Se realiza una búsqueda en rejilla 2D (*Grid Search*) evaluando la CV sobre una malla de combinaciones (α, λ).

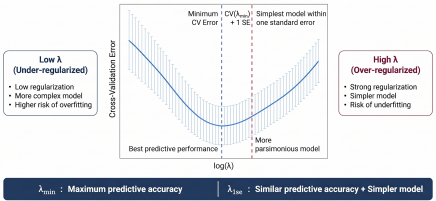
3.5.2. Comparación de errores: Reglas de selección de λ.

En el perfil de curva de error de validación cruzada frente a λ, se identifican dos puntos de corte estándar (Hastie et al., 2015):

- $\lambda_{\text{mín}}$ **(Mínimo CV):** Valor de λ que minimiza exactamente el $CV_{(\lambda)}$. Maximiza el rendimiento predictivo puro fuera de muestra (James et al., 2015).
- $\lambda_{\mathbf{1se}}$ **(One Standard Error Rule):** Valor de λ más parsimonioso cuyo error no dista más de 1 error estándar del mínimo (Hastie et al., 2015):

$$CV_{(\lambda_{\mathbf{1se}})} \leq CV_{(\lambda_{\text{mín}})} + SE\left(CV_{(\lambda_{\text{mín}})}\right)$$

  Selecciona modelos más simples con rendimiento equivalente (Hastie et al., 2015).



3.5.3. ¿Qué modelo elegir?

Característica	MCO (OLS)	Ridge	LASSO	Elastic Net
Penalización	Ninguna	ℓ_2 (β^2)	ℓ_1 ($\lvert\beta\rvert$)	$(1-\alpha)\ell_2 + \alpha\ell_1$
Solución analítica	Sí: $(X^TX)^{-1}X^TY$	Sí: $(X^TX+\lambda I)^{-1}X^TY$	No (Algorítmica)	No (Algorítmica)
Selección de variables	No	No	Sí ($\beta_j = 0$)	Sí ($\beta_j = 0$)
Multicolinealidad	Inestable	Excelente	Inestable (Aísla 1)	Excelente (Grupo)
Alta dimensión ($p > n$)	No computable	Sí	Sí (Máx. n)	Sí ($> n$)
Hiperparámetros	0	λ	λ	(λ, α)

3.5.3. ¿Qué modelo elegir?

- **Usar Ridge Regression si:**
  - Se asume que la mayoría de los predictores son relevantes y aportan información pequeña pero no nula.
  - Existe multicolinealidad severa y se requiere máxima estabilidad en las estimaciones.
- **Usar LASSO si:**
  - Se sospecha que solo un subconjunto reducido de variables explicativas influye en la respuesta (*esparsidad*).
  - La interpretabilidad es un requisito clave (e.g., scoring de riesgo o tarificación).
- **Usar Elastic Net si:**
  - Existen grupos de predictores fuertemente correlacionados que deben seleccionarse o descartarse juntos (*grouping effect*) (Zou and Hastie, 2005).
  - El número de predictores supera ampliamente al de observaciones ($p \gg n$).

3.5. ¿Cómo seleccionar entre ellos?



Ejemplo práctico en R: Selección global mediante `glmnet`.

Más allá de Ridge, LASSO y Elastic Net (Hastie et al., 2015)

- **Fused LASSO (Tibshirani et al., 2005; Hastie et al., 2015):** Penaliza tanto el tamaño de los coeficientes ($|\beta_j|$) como la diferencia entre coeficientes sucesivos ($|\beta_j - \beta_{j-1}|$). Promueve que coeficientes adyacentes sean iguales (ideal para series temporales o datos con orden/estrucutra espacial).
- **Group LASSO (Yuan and Lin, 2006):** Aplica una penalización ℓ_2 sobre grupos de variables ($\sum_g \|\beta_g\|_2$). Selecciona o descarta bloques enteros de covariables (e.g., todos los niveles de una variable cualitativa/factor).
- **Adaptive LASSO (Zou, 2006):** Incorpora pesos ponderados en la penalización ℓ_1 ($\sum w_j|\beta_j|$). Otorga menor penalización a coeficientes grandes para corregir el sesgo.
- **Bridge Regression / Penalización ℓ_q (Fu, 1998):** Generaliza la penalización a norma ℓ_q con $\sum |\beta_j|^q$. Si $q \leq 1$ genera esparsidad; si $q \to 0$ se aproxima a la selección del mejor subconjunto.

Referencias I

Antonio, K. (2023). Hands on machine learning R module. Technical report, Github-repository. https://github.com/katrienantonio/hands-on-machine-learning-R-module-1.

Denuit, M., Hainaut, D., and Trufin, J. (2019). *Effective statistical learning methods for actuaries I: GLMs and extensions*, volume 1. Springer.

Fu, W. J. (1998). Penalized regressions: the bridge versus the lasso. *Journal of Computational and Graphical Statistics*, 7(3):397–416.

Hastie, T., Tibshirani, R., and Wainwright, M. (2015). Statistical learning with sparsity. *Monographs on Statistics and Applied Probability*, 143(143):8.

Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.

Huang, F. (2026). Actuarial data science: Open learning resource (v1.0.0). Technical report, Zenodo-repository. https://doi.org/10.5281/zenodo.20718647.

James, G., Witten, D., Hastie, T., and Tibshirani, R. (2015). *An Introduction to Statistical Learning: With Applications in R*. Springer, 6 edition. Corrected 6th printing.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 58(1):267–288.

Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., and Knight, K. (2005). Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 67(1):91–108.

Wüthrich, M. V., Richman, R., Avanzi, B., Lindholm, M., Maggi, M., Mayer, M., Schelldorfer, J., and Scognamiglio, S. (2025). AI tools for actuaries. *SSRN Manuscript*. http://dx.doi.org/10.2139/ssrn.5162304.

Yuan, M. and Lin, Y. (2006). Model selection and estimation in regression with grouped variables. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 68(1):49–67.

Referencias II

Zou, H. (2006). The adaptive lasso and its oracle property. *Journal of the American Statistical Association*, 101(476):1418–1429.

Zou, H. and Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(2):301–320.

MATERIAL DOCENTE

Autoría

David Atance del Olmo

Departamento de Economía y Dirección de Empresas
Universidad de Alcalá

CC BY-NC-SA 4.0

© 2026 David Atance del Olmo

Este material se distribuye bajo la licencia Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional.

Consultar la licencia CC BY-NC-SA 4.0